

CLUSTERING

1. Pengertian Clustering

Clustering adalah teknik **unsupervised** learning untuk mengelompokkan data ke dalam beberapa kelompok (cluster) berdasarkan kemiripan karakteristik, tanpa menggunakan label sebelumnya. Cluster analysis adalah sebuah teknik eksplorasi data yang bertujuan untuk membagi data ke dalam kelompok-kelompok dimana data dalam satu kelompok yang sama memiliki variasi sekecil mungkin (homogen) dan antar kelompok memiliki variasi sebesar mungkin. Cluster analysis berguna untuk mengungkapkan karakteristik dari setiap struktur atau pola yang terkandung dalam data. Analisis klaster dapat menyederhanakan data berukuran besar sehingga data dapat dipahami dengan mudah dan informasi dapat diambil secara lebih efisien

Dalam konteks RME, clustering digunakan untuk:

- Mengidentifikasi pola penyakit tersembunyi
- Mengelompokkan pasien berdasarkan risiko kesehatan
- Mendukung pengambilan keputusan klinis awal

2. Peran Clustering dalam Rekam Medis Elektronik

Clustering membantu rumah sakit dan fasilitas kesehatan dalam:

- Segmentasi pasien
- Deteksi kelompok risiko tinggi
- Perencanaan layanan kesehatan berbasis data
- Efisiensi biaya dan sumber daya

Perbedaan **Clustering** dan **Klasifikasi**

Aspek	Clustering	Klasifikasi
Jenis Pembelajaran	Unsupervised learning	Supervised learning
Label Data	Tidak menggunakan label	Menggunakan label kelas
Tujuan	Menemukan pola atau struktur data	Memprediksi kelas data
Pengetahuan Awal	Tidak perlu definisi kelas	Perlu definisi kelas sejak awal

Aspek	Clustering	Klasifikasi
Output	Kelompok (cluster) baru	Kelas yang sudah ditentukan
Sifat Analisis	Eksploratif	Prediktif
Peran Pakar	Interpretasi setelah clustering	Validasi sebelum pelatihan
Evaluasi	Silhouette, Davies-Bouldin	Accuracy, Precision, Recall
Fleksibilitas Kelas	Jumlah cluster bisa berubah	Jumlah kelas tetap
Contoh Algoritma	K-Means, DBSCAN	SVM, Naive Bayes, KNN

Perbedaan dari Sisi Tujuan Analisis

- Clustering: *Apa pola alami dalam data?*
- Klasifikasi: *Data ini termasuk kelas apa?*

Contoh Singkat

- Clustering: Mengelompokkan pasien berdasarkan kemiripan data kesehatan tanpa mengetahui risikonya.
- Klasifikasi: Memprediksi risiko penyakit pasien berdasarkan data dan label sebelumnya.

Kesimpulan

- Clustering digunakan untuk eksplorasi data.
- Klasifikasi digunakan untuk prediksi kelas.

3. Pemilihan Algoritma

Algoritma	Alasan Pemilihan
K-Means	Sederhana dan cepat
Hierarchical	Mudah divisualisasikan
DBSCAN	Mendeteksi outlier pasien

4. Proses Clustering

Misal digunakan K-Means dengan $k = 3$:

- Cluster 1
- Cluster 2

- Cluster 3

5. Contoh Hasil Clustering

Cluster	Karakteristik Pasien	Interpretasi Klinis
Cluster 1	Usia < 40, tekanan darah normal, gula darah normal	Pasien sehat
Cluster 2	Usia 40–60, tekanan darah borderline, IMT tinggi	Risiko sedang
Cluster 3	Usia > 60, hipertensi, gula darah tinggi	Risiko tinggi penyakit kronis

6. Evaluasi Clustering

Matrix Evaluasi yang Digunakan

Metrik	Pengertian Singkat	Kriteria Hasil Baik	Widget di Orange Data Mining	Keterangan Penggunaan
Silhouette Score	Mengukur kekompakan dan keterpisahan data dalam cluster	Nilai mendekati 1	Silhouette Plot	Menampilkan nilai silhouette per data dan nilai rata-rata
Davies–Bouldin Index	Mengukur kemiripan antar cluster	Nilai semakin kecil	Test and Score	Digunakan untuk membandingkan kualitas clustering
Calinski–Harabasz Index	Mengukur rasio variasi antar cluster dan dalam cluster	Nilai semakin besar	Test and Score	Umum digunakan untuk menentukan jumlah cluster terbaik

7. Manfaat Clustering pada RME

Manfaat	Dampak
Deteksi dini penyakit	Intervensi lebih cepat
Segmentasi pasien	Pelayanan lebih tepat
Efisiensi biaya	Pengurangan rawat inap
Pendukung keputusan klinis	Data-driven healthcare

8. Keterbatasan

- Tidak menghasilkan diagnosis pasti
- Sensitif terhadap pemilihan variabel
- Membutuhkan interpretasi klinis lanjutan

9. Kesimpulan


Clustering pada RME merupakan alat analitik eksploratif yang efektif untuk:

- Mengungkap pola kesehatan pasien
- Mendukung layanan kesehatan cerdas
- Meningkatkan mutu pelayanan medis

10. Arah Pengembangan


- Integrasi dengan klasifikasi risiko
- Kombinasi dengan posterior probability
- Penerapan pada big data kesehatan

11. Praktik




Gambar 1. Workflow Clustering

a. File



b. k-Means



1) Number of Clusters: Fixed

Opsi Fixed berarti:

- Jumlah cluster ditentukan secara tetap (manual) oleh pengguna
- Algoritma K-Means hanya dijalankan satu kali dengan nilai k tersebut

Contoh

- Number of Clusters: Fixed

- Nilai $k = 3$, Artinya data akan dibagi menjadi **3 cluster**.

2. Number of Clusters: From ... to ...

Opsi From ... to ... berarti:

- K-Means dijalankan berulang kali dengan jumlah cluster yang berbeda
- Nilai k berada dalam rentang tertentu

Contoh

- Number of Clusters: From 2 to 6, Artinya K-Means akan dijalankan untuk: $k = 2, 3, 4, 5$, dan 6

c. Data Table

	ID_Pasien	Cluster	Silhouette	Umur	BMI	Tr.
479	P0479	C2	0.503598	77	26.4	
480	P0480	C2	0.546112	50	25.5	
481	P0481	C1	0.522425	69	28.0	
482	P0482	C2	0.587007	78	21.8	
483	P0483	C3	0.525697	38	24.6	
484	P0484	C3	0.57698	49	25.1	
485	P0485	C3	0.595107	40	29.3	
486	P0486	C2	0.509273	50	22.2	
487	P0487	C3	0.529236	20	26.9	
488	P0488	C1	0.55188	35	27.0	
489	P0489	C3	0.581466	42	32.6	
490	P0490	C3	0.546063	59	22.0	
491	P0491	C2	0.548479	48	23.4	
492	P0492	C2	0.597951	71	22.3	
493	P0493	C3	0.527557	75	19.3	
494	P0494	C1	0.515586	20	33.1	
495	P0495	C2	0.602899	57	21.0	
496	P0496	C2	0.573616	63	22.7	
497	P0497	C3	0.522832	41	31.3	
498	P0498	C2	0.507947	67	19.0	
499	P0499	C1	0.508271	49	29.0	

2) Kolom Cluster

Kolom Cluster merupakan kolom yang menunjukkan hasil pengelompokan (label cluster) yang diberikan algoritma clustering kepada setiap data/objek.

3) Kolom Silhouette

Dalam clustering, silhouette (atau *Silhouette Coefficient / Silhouette Score*) adalah ukuran evaluasi kualitas hasil pengelompokan yang menunjukkan seberapa baik setiap data ditempatkan di dalam clusternya dibandingkan dengan cluster lain.

Nilai silhouette berada pada rentang:

$$-1 \leq s(i) \leq 1$$

Interpretasinya:

Nilai Silhouette	Makna
Mendekati +1	Data sangat cocok dengan clusternya
Sekitar 0	Data berada di batas antar cluster
Mendekati -1	Data lebih cocok dengan cluster lain (salah cluster)


Silhouette mengukur dua hal sekaligus:

1. Kekompakan (cohesion) → seberapa dekat suatu data dengan anggota dalam cluster yang sama
2. Pemisahan (separation) → seberapa jauh data tersebut dari cluster terdekat lainnya

Silhouette menunjukkan seberapa “tepat” sebuah data berada di clusternya.

d. Scatter Plot

Komponen Scatter Plot berfungsi memetakan atribut data ke posisi, warna, bentuk, ukuran, dan label titik agar pola data dan hasil clustering mudah dianalisis secara visual.



1) Axis X (Sumbu X)

Axis X merupakan:

- Atribut/fitur data yang ditampilkan pada sumbu horizontal
- Menunjukkan nilai variabel pertama

Contoh:

- Axis X = BMI
- Titik semakin ke kanan → nilai BMI semakin tinggi

Makna:

- Membantu melihat pola perubahan variabel X
- Digunakan untuk membandingkan distribusi data antar cluster

2) Axis Y (Sumbu Y)

Axis Y merupakan:

- Atribut/fitur data yang ditampilkan pada sumbu vertikal
- Menunjukkan nilai variabel kedua

Contoh:

- Axis Y = Gula_Darah
- Titik semakin ke atas → nilai gula darah semakin tinggi

Makna:

- Melihat hubungan antara Axis X dan Axis Y
- Mengidentifikasi pemisahan cluster secara visual

3) Color (Warna)

Color digunakan untuk:

- Memberi warna berbeda pada titik berdasarkan suatu atribut

Umumnya dipilih:

- Cluster (hasil K-Means)
- Kelas (jika ada)
- Kategori tertentu

Contoh:

- Color = Cluster
- Setiap warna merepresentasikan satu cluster

Makna:

- Memudahkan identifikasi kelompok
- Menilai apakah cluster terpisah jelas atau tumpang tindih

4. Shape (Bentuk)

Shape menentukan:

- Bentuk simbol titik (lingkaran, segitiga, kotak, dll)
- Berdasarkan atribut kategorikal

Contoh:

- Shape = Jenis Kelamin
 - Lingkaran = Laki-laki
 - Segitiga = Perempuan

Makna:

- Menampilkan variabel kategorikal tambahan
- Membandingkan distribusi kategori dalam tiap cluster

4) Size (Ukuran)

Size mengatur:

- Ukuran titik berdasarkan nilai suatu atribut numerik

Contoh:

- Size = Kolesterol
- Titik besar → kolesterol tinggi
- Titik kecil → kolesterol rendah

Makna:

- Menunjukkan intensitas atau tingkat risiko
- Menambah dimensi informasi tanpa menambah sumbu

5) Label (Teks Penanda)

Label digunakan untuk:

- Menampilkan teks identitas data di dekat titik

Contoh:

- Label = ID Pasien
- Label = Nama Sampel

Makna:

- Mengidentifikasi data tertentu secara spesifik

- Berguna untuk analisis detail atau outlier

Catatan:

- Jika data banyak, label biasanya dimatikan agar grafik tidak penuh

7. Contoh Pengaturan Scatter Plot

Misal dataset:

Umur, BMI, Tekanan_Darah, Gula_Darah, Kolesterol, Aktivitas_Fisik, Cluster

Komponen	Atribut
Axis X	BMI
Axis Y	Gula_Darah
Color	Cluster
Shape	Aktivitas_Fisik (kategori)
Size	Kolesterol
Label	ID Pasien

Visualisasi ini menunjukkan:

- Pola BMI vs gula darah
- Perbedaan cluster
- Tingkat kolesterol
- Identitas pasien tertentu

Tugas :

1. Hitung dan terapkan clustering menggunakan algoritma K-Means, selanjutnya lakukan interpretasi hasil visualisasi scatter plot berdasarkan data berikut:

No	Axis X	Axis Y
1	BMI	Gula_Darah
2	Umur	Tekanan_Darah
3	BMI	Kolesterol
4	Gula_Darah	Aktivitas_Fisik
5	Umur	BMI

2. Dataset : dataset_clustering_1000.csv
3. K=3
4. Dokumen yang dikumpulkan Screenshot workflow, screenshot hasil predictions (widget **Scatter Plot** sebanyak 5 dan hasil analisis dari masing-masing gambar) (pdf)
5. Link pengumpulan : <https://forms.gle/x3dHECP7t2ehDsCq9> maksimal Sabtu, 31 Januari 2026 pukul 23.00 WIB.